

Apuntes ACSI

Serafi Nebot Ginard

08/06/2025

Contents

1	Tema 1	2
2	Tema 2	3
3	Tema 3	4
3.1	Medida y rendimiento	4
3.2	Índices de rendimiento	4
3.3	Aproximaciones	5
3.4	Referenciación (benchmarking)	6
3.5	Estrategias de análisis	6
4	Tema 4	7
4.1	Hipótesis del equilibrio de flujo	7
4.2	Ley de Little	7
4.3	Ley de la utilización	7
4.4	Ley del flujo forzado	7
4.5	Ley general del tiempo de respuesta	8
4.6	Ley del tiempo de respuesta interactiva	8
5	Tema 5	9
5.1	Resolución redes cerradas	10
5.2	Límites optimistas del rendimiento	11
5.3	Técnicas de mejora	13
6	Tema 6	14
6.1	Técnicas de agrupamiento	14
7	Tema 7	16
7.1	Patrones de datos	16
7.2	Técnicas de predicción	16

1 Tema 1

$$\text{Aceleracion} = \frac{T_B}{T_A}$$

por convención $T_B > T_A$ tal que $\frac{T_B}{T_A} = 1 + \frac{n}{100}$ dónde n es el porcentaje de incremento.

$$\text{Cambio relativo}_{B,A} = \frac{T_B - T_A}{T_A}$$

Ley de Amdhal

$$\text{Aceleracion} = \frac{T_{\text{original}}}{T_{\text{mejorado}}} = \frac{s + p}{s + \frac{p}{k}} = \frac{1}{1 - p + \frac{p}{k}}$$

$$\text{Aceleracion maxima} = \lim_{k \rightarrow \infty} \frac{1}{s + \frac{p}{k}} = \frac{1}{s + 0} = \frac{1}{s}$$

$$\text{Aceleracion general} = \frac{1}{(1 - \sum_{i=1}^n p_i) + \sum_{i=1}^n \frac{p_i}{k_i}}$$

Ley de Gustafson

$$\text{Aceleracion} = \frac{T_{\text{secuencial}}}{T_{\text{paralelo}}} = \frac{s + p \cdot k}{s + p} = \frac{s + p \cdot k}{1} = s + p \cdot k$$

Amdhal es la versión pesimista y Gustafson es optimista. La realidad normalmente esta entre las dos.

$$\text{Eficiencia}(k) = \frac{\text{Aceleracion}}{k}$$

$$\text{Eficiencia}_W = \frac{\text{Tiempo de trabajo efectivo}}{\text{Tiempo de trabajo total}} = \frac{W}{W + Ov} = \frac{1}{1 + \frac{Ov}{W}}$$

$$\frac{\text{Rendimiento}}{\text{Coste}} = \frac{\frac{1}{T}}{C} = \frac{1}{T \cdot C}$$

$$\text{Energia consumida} = \text{Potencia} \cdot \text{Tiempo} = [Ws]$$

$$EDP = \text{Energia consumida} \cdot \text{Tiempo} = \text{Potencia} \cdot \text{Tiempo}^2 = [Ws^2]$$

2 Tema 2

Monitorización por:

- Eventos: sólo se guardan datos cuando ocurre un evento
- Rastreo (tracing): igual que eventos pero guardando más información (normalmente el estado)
- Muestreo (sampling): guardar información en intervalos de tiempo regulares
- Medición indirecta: cuando no se puede medir observando eventos (calcular a partir de datos medibles)


Atributos de monitores:

- Interferencia o sobrecarga (overhead)
- Precisión (calidad de medida)
- Resolución (frecuencia de medida)
- Ámbito o dominio de medida (que mide)
- Anchura (bits de información)
- Capacidad de sistensis de datos
- Coste
- Facilidad de instalación y uso

Tipos de monitores:

- Software (programas instalados en el sistema)
- Hardware (dispositivos externos al sistema)
- Híbridos (combinación de los dos anteriores)

$$\text{Sobrecarga} = \frac{\text{Tiempo de ejecucion del monitor}}{\text{Intervalo de medida}}$$



|-----| -> Tiempo de ejecución del monitor

|-----| -> Tiempo de ejecución del programa a monitorizar

|-----| -> Intervalo de monitorización

3 Tema 3

3.1 Medida y rendimiento

Dispositivo	Medida
CPU	MIPS FLOPS CPU Tiempo de ejecución
Memoria Principal	Lecturas/s Escrituras/s Tiempo de espera Tiempo de lectura Tiempo de escritura
E/S	Lecturas/s Escrituras/s Tiempo de espera Tiempo de lectura Tiempo de escritura

Atributos de la calidad de medida:

- Fácil de medir
- Repetible
- Confiable: resultados seguros
- Lineal: valores de mediciones linealmente proporcionales
- Consistente: mismas unidades entre diferentes sistemas medidos
- Independiente: no está influenciada: no está influenciada

$$\text{Tiempo de CPU} = \text{Ciclos de CPU} \cdot \text{Tiempo de ciclo de reloj} = \frac{\text{Ciclos de CPU}}{\text{Frecuencia de reloj}}$$

CPI (Cycles Per Instruction):

$$CPI = \frac{\text{Ciclos de CPU}}{\text{Numero de instrucciones}}$$

Cada tipo de instrucción necesita un diferente número de ciclos. Por ejemplo:

Tipo instrucción	Frecuencia aparición (f_i)	Tiempo ejecución en ciclos (t_i)
Store	0.12	2
Load	0.21	2
ALU	0.43	1
Jump	0.24	2

$$\text{Con } \sum_{i=1}^n f_i = 1 \implies 0.12 + 0.21 + 0.43 + 0.24 = 1$$

$$CPI = \sum_{i=1}^4 t_i \cdot f_i = 0.12 \cdot 2 + 0.21 \cdot 2 + 0.43 \cdot 1 + 0.24 \cdot 2 = 1.57$$

$$\text{Tiempo de CPU} = \text{Numero de instrucciones} \cdot CPI \cdot \text{Tiempo ciclo de reloj} \implies \frac{\text{Numero de instrucciones}}{\text{Tiempo de CPU}} = \frac{\text{Frecuencia de reloj}}{CPI}$$

3.2 Índices de rendimiento

MIPS (million of instructions per second):

$$MIPS = \frac{\text{Instrucciones ejecutadas}}{\text{Tiempo de ejecución} \cdot 10^6} = \frac{\text{Frecuencia de reloj CPU}}{CPI \cdot 10^6}$$

MIPS relativos (referidos a una máquina de referencia; normalización):

$$MIPS_{relativos} = \frac{\text{Tiempo de referencia}}{\text{Tiempo de ejecución}} \cdot MIPS_{referencia}$$

MFLOPS (millioin of floating-point operations per second):

$$MFLOPS = \frac{\text{Operaciones de coma flotante ejecutadas}}{\text{Tiempo de ejecución} \cdot 10^6}$$

Hay diferentes tipos de operaciones de coma flotante que tienen un coste diferente, por ejemplo:

- suma, resta, multiplicación, comparación, negación: poco costosas
- división, raíz cuadrada: costosas
- trigonométricas: muy costosas

Por lo que se pueden normalizar:

- ADD, SUB, COMPARE, MUL -> 1 operación normalizada
- DIV, SQRT -> 4 operaciones normalizadas
- EXP, SIN, ATAN -> 8 operaciones normalizadas

Los MFLOPS normalizados serían la suma ponderada de la cantidad de cada tipo de instrucción por su coste normalizado dividido por el tiempo de ejecución. Por ejemplo supongamos que se ejecutan 109970178 operaciones de coma flotante y 15682333 de las cuales son divisiones:

$$MFLOPS = \frac{109970178}{94 \cdot 10^6} = 1.2$$

$$MFLOPS_{normalizados} = \frac{(109970178 - 15682333) \cdot 1 + 15682333 \cdot 4}{94 \cdot 10^6} = 1.7$$

	Facilidad	Repetitividad	Confiabilidad	Linealidad	Consistencia	Independencia
GHz						
MIPS						
MFLOPS						

3.3 Aproximaciones

Media aritmética:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Media aritmética ponderada:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \cdot w_i, \text{ con } \sum_{i=1}^n w_i = 1$$

- Útil para tiempos de respuesta
- No se ha de utilizar con frecuencias

- Se recomienda normalizar el resultado en lugar de cada x_i

Media armónica:

$$\bar{x} = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

Media armónica ponderada:

$$\bar{x} = \frac{n}{\sum_{i=1}^n \frac{w_i}{x_i}}, \text{ con } \sum_{i=1}^n w_i = 1$$

- Útil para frecuencias o unidades de tiempo en el denominador (MIPS, MFLOPS)
- No se ha de utilizar con tiempos de respuesta
- Se recomienda normalizar el resultado en lugar de cada x_i

Media geométrica:

$$\bar{x} = \left(\prod_{i=1}^n x_i \right)^{\frac{1}{n}}$$

Media geométrica ponderada:

$$\bar{x} = \prod_{i=1}^n x_i^{w_i}, \text{ con } \sum_{i=1}^n w_i = 1$$

- No es útil ni para tiempos de respuesta ni para frecuencias
- Única virtud: manitene el mismo orden en las comparaciones con valores normalizados (consistencia)

3.4 Referenciación (benchmarking)

$$\frac{R_A}{R_B} = \frac{T_B}{T_A} = 1 + \frac{n}{100}, \text{ o también, } \frac{R_A - R_B}{R_B} \cdot 100 = n$$

3.5 Estrategias de análisis

Recomendaciones para las medias:

- Tiempos: media aritmética
- Frecuencias o velocidades: media armónica
- Índices de rendimiento: media geométrica (a riesgo de reordenar los resultados)
- Porcentajes: media aritmética
- Tiempos: primero se hace la media aritmética y luego se normaliza
- Valores muy extremos: se eliminan los extremos (si se puede) y luego se hace la media aritmética

4 Tema 4

Tiempo de respuesta = Tiempo de espera + Tiempo de servicio

- T : duración del periodo de medida
- N : numero de trabajos en el sistema
- Z : timepo de reflexión (think time)
- A_i : numero de trabajos que llegan (arrivals)
- C_i : numero de trabajos que se van (completions)
- B_i : tiempo de ocupación (busy time)
- $\lambda_i = \frac{A_i}{T}$: tasa de llegadas (arrival rate)
- $X_i = \frac{C_i}{T}$: productividad (throughput)
- $S_i = \frac{B_i}{C_i}$: tiempo de servicio (service time)
- $V_i = \frac{C_i}{C_0}$: razón de visita (visit ratio)
- $U_i = \frac{B_i}{T}$: utilización (utilization)
- $D_i = V_i \cdot S_i$: demanda de servicio (service demand)
- W_i : timepo de espera en cola (waiting time)
- Q_i : trabajos en cola de espera (waiting customers)
- $R_i = W_i + S_i$: tiempo de respuesta (response time)
- $N_i = Q_i + U_i$: trabajos en toda la estación (cola más servidor)
- $\lambda_0 = \frac{A_0}{T}$: tasa de llegadas del sistema
- $X_0 = \frac{C_0}{T}$: productividad del sistema

4.1 Hipótesis del equilibrio de flujo

- Supone que el sistema trabaja en estado estable (estacionario, no transitorio)
- El sistema cumple el supuesto de equilibrio de flujo si para cada dispositivo: $\lambda_i = X_i$ o bien $A_i = C_i$
- Para intervalo de observación suficientemente largos:

$$\left| \frac{A_i - C_i}{C_i} \right| \approx 0$$

$$A_i = C_i \implies \lambda_i = X_i$$

4.2 Ley de Little

$$N_i = \lambda_i \cdot R_i = X_i \cdot R_i$$

$$Q_i = \lambda_i \cdot W_i = X_i \cdot W_i$$

4.3 Ley de la utilización

$$U_i = \frac{B_i}{T} = \frac{C_i}{T} \frac{B_i}{C_i} = X_i S_i \implies U_i = X_i S_i$$

$$U_i = \lambda_i S_i = X_i S_i$$

4.4 Ley del flujo forzado

$$V_i = \frac{C_i}{C_0} \implies C_i = C_0 V_i \implies \frac{C_i}{T} = \frac{C_0}{T} V_i \implies X_i = X_0 V_i$$

$$U_i = X_i S_i = X_0 V_i S_i = X_0 D_i$$

4.5 Ley general del tiempo de respuesta

En general

$$R \neq \sum_{i=1}^K R_i$$

En particular

$$R = \sum_{i=1}^K V_i R_i$$

4.6 Ley del tiempo de respuesta interactiva

- $N_Z = XZ$: cantidad de trabajos reflexionando
- $N_R = XR$: cantidad de trabajos trabajando

$$N = N_Z + N_R = XZ + XR = X(Z + R) \implies R = \frac{N}{X} - Z$$

5 Tema 5


$$R_i = (N_i + 1)S_i = (X_i R_i + 1)S_i \implies R_i = \frac{S_i}{1 - X_i S_i} = \frac{S_i}{1 - U_i}$$

Resolución de redes abiertas

$$U_i = X_i S_i = \lambda V_i S_i$$

$$R_i = \frac{S_i}{1 - U_i}$$


$$R = \sum_{i=1}^k V_i R_i = \sum_{i=1}^k \frac{V_i S_i}{1 - U_i}$$



Dispositivo	V _i	S _i
CPU	9	0.01
DISCO	4	0.02
DISCO	4	0.02


Hay un valor máximo
(capacidad del sistema)

5.1 Resolución redes cerradas



Tiempo de reflexión		2
Dispositivo	V_i	S_i
CPU	10	0.01
DISCO	5	0.02
DISCO	4	0.03

El incremento es lineal



Tiempo de reflexión		2
Dispositivo	V_i	S_i
CPU	10	0.01
DISCO	5	0.02
DISCO	4	0.03

$$R_i(n) = (N_i(n-1) + 1)S_i, \text{ con } N_i(0) = 0$$


$$R(n) = \sum_{i=1}^k V_i R_i(n), X(n) = \frac{n}{Z + R(n)}$$

$$N_i(n) = X(n)V_iR_i(n)$$


$$X_i(n) = X(n)V_i$$

$$U_i(n) = X(n)V_iS_i$$

5.2 Límites optimistas del rendimiento




Operación "normal"




Sistema saturado

El sistema alcanza su productividad máxima

$$U_i = U_j, \forall i, j \Rightarrow D_i = D_j, \forall i, j$$



Todos los dispositivos son cuellos de botella



Localización del cuello de botella:

$$D_b = \max_{i=1,\dots,k} D_i = \max_{i=1,\dots,k} V_i S_i = V_b S_b$$

$$U_b = \max_{i=1,\dots,k} U_i = \max_{i=1,\dots,k} X_i S_i = X_b S_b = X V_b S_b = X D_b$$

$$D = \sum_{i=1}^k D_i$$


Sistemas abiertos

$$U_b = X_b S_b = X D_b = \lambda D_b$$

$$U_b = 1 \implies \lambda D_b = 1 \implies \lambda = \frac{1}{D_b}$$

$$X_{opt} = \frac{1}{D_b}$$

$$R_{opt} = \sum_{i=1}^k k D_i = D$$



Sistemas cerrados

$$R_{opt} = \sum_{i=1}^k k D_i = D$$


$$R_{opt} = \frac{N}{X_{opt}} - Z \implies X_{opt} = \frac{N}{D + Z}$$

$$R_{opt} = \frac{N}{X_{opt}} - Z \implies R_{opt} = N D_b - Z$$

Punto teórico de saturación N^* :


$$D = ND_b - Z \Rightarrow N = \frac{D+Z}{D_b} \Rightarrow N^* = \left\lceil \frac{D+Z}{D_b} \right\rceil$$

Tiempo de respuesta



$$R_{opt} = \max \{D, D_b N - Z\}$$

Productividad



$$X_{opt} = \min \left\{ \frac{N}{D+Z}, \frac{1}{D_b} \right\}$$

5.3 Técnicas de mejora

1. Actualización (upgrading): Reemplazar dispositivos por otros más rápidos, añadir más dispositivos para realizar más tareas en paralelo, etc
2. Ajuste (tuning): optimizar el funcionamiento de todos los componentes, muchos ajustes se hacen en el sistema operativo

6 Tema 6

Utilización de medias

- Si la carga es homogénea se puede utilizar medias
- Si la carga es heterogénea se utiliza el agrupamiento (clustering)


6.1 Técnicas de agrupamiento

1. Tomar una muestra
2. Seleccionar parámetros
3. Transformar parámetros si fuese necesario
4. Eliminar valores extremos
5. Escalar las observaciones
6. Seleccionar una métrica para la distancia
7. Construir los grupos o clusters
8. Interpretar los grupos
9. Cambiar la agrupación si fuese necesario y repetir desde 3 a 7
10. Seleccionar los componentes representativos

Clustering method, Minimum Spanning Trees (MST):


	Program				
Program	A	B	C	D	E
A	0	$\sqrt{2}$	$\sqrt{5}$	$\sqrt{5}$	$\sqrt{13}$
B		0	$\sqrt{5}$	$\sqrt{5}$	$\sqrt{13}$
C			0	$\sqrt{18}$	$\sqrt{32}$
D				0	$\sqrt{2}$
E					0

Mínima distancia → fusión de clases



Repetimos el proceso

- El centroide de AB es $\{(2+3)/2, (4+5)/2\} = \{2.5, 4.5\}$
- DE = $\{4.5, 2.5\}$




	Program		
Program	AB	C	DE
AB	0	$\sqrt{4.5}$	$\sqrt{10.25}$
C		0	$\sqrt{24.4}$
DE			0

Mínimo → fusión

El árbol de extensión mínima se conoce con el nombre de dendrograma





- Cada rama es un grupo o cluster, y su altura finaliza donde se fusiona con otro grupo



Se puede cortar el árbol a cualquier altura, lo que representa un criterio de máxima distancia inter-grupo

7 Tema 7

7.1 Patrones de datos



7.2 Técnicas de predicción

Error cuadrático medio

$$\frac{1}{n} \sum_{t=1}^n (y(t) - f(t))^2$$

Regresión lineal

Útil para datos no estacionales que muestran una tendencia.

$$f(x) = a + bx$$

$$b = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

$$a = \bar{y} - b \bar{x}$$

Medias móviles

Apropiada para predicciones a corto plazo

$$f(t+1) = \frac{y(t) + \cdots + y(t-n+1)}{n}$$

Se debe elegir un valor de n que minimize el error de predicción.

Suavizado exponencial

Para datos no estacionales que no muestran una tendencia sistemática.

$$f(t+1) = (1 - \alpha)f(t) + \alpha(y(t+1)) = f(t) + \alpha(y(t+1) - f(t)), \text{ con } 0 < \alpha < 1$$